

MEMORIA FIN DE MASTER

Jose Manuel Vera

1 de junio de 2016

CLASIFICACIÓN DOCUMENTAL: AYUDANDO A LEER

INTRODUCCION

Más de 300 documentos de todo tipo se deben leer, clasificar y etiquetar, diariamente, por diversos departamentos. Cada nuevo proyecto en gestión genera incrementos enormes en el número de archivos (del orden de varios miles de golpe) que provocan sobrecarga/retrasos en todos los procesos cotidianos de trabajo.

Se desea acelerar/aligerar este proceso de clasificación de la documentación y automatizarlo en la medida de lo posible, al menos para aminorar la carga de trabajo y/o facilitar la vida a los diferentes departamentos.

No existen intentos previos de solucionar este problema.

La propuesta es:

“Se puede extraer suficiente información de los documentos, **ANTES** de su lectura por una persona, de manera que se facilite un tratamiento y/o extracción específicos, y acelerar así el proceso o al menos impedir los retrasos en el resto de tareas”.

El contenido se encuentra repartido en carpetas de un servidor en diversos formatos de documento: DOC, DOCX, RTF y PDF.

ADVERTENCIA

Debido a la información confidencial contenida en los documentos, estos no se aportan a la memoria.

En esta, exclusivamente se reseñan los hitos del proceso y el análisis efectuado con R. El proyecto consta de carpetas para los datos en carpeta *data*, reportes de salida en *reports*, código bash/python en *code*.

Entre otros, se pueden comprobar:

- iPython Notebook con analisis exploratorio (code/PRELIMINAR.ipynb)
- Resultado en HTML del iPython Notebook (reports/PRELIMINAR.html)
- Bash Script para el proceso completo y gestion de archivos (code/extraccion.sh)

Este bash script tiene parámetros obligatorios:

carpeta origen, destino, numero de procesadores, nombre del documento resumen, departamento (en este orden).

- Bash extracción resumen de datos para 1 departamento (code/resumen_juridico.sh)

ENTORNO

Rstudio + Jupyter Notebook con Pandas y Matplotlib en cliente Windows 7. Servidor de archivos Debian Linux con pdftotext, tesseract, convert, Libre Office CLI, parallel, ImageMagick, unoconv, poppler-utils, unidoc.

```
(.packages())

[1] "knitr"      "gridExtra"  "ggplot2"    "party"      "strucchange" "sandwich"
[7] "stats4"     "mvtnorm"    "grid"       "zoo"        "stats"       "graphics"
[13] "utils"      "datasets"   "methods"    "base"       "wordcloud"   "RColorBrewer"
[19] "tm"         "NLP"        "graphics"   "grDevices"  "SnowballCC"  "biclust"
[25] "igraph"     "fpc"        "topicmodels" "Rcpp"       "NMF"         "modeltools"  "grDevices"
[32] "ggplot2"    "cluster"    "grDevices"

# SI DESEA INSTALAR LOS PAQUETES NECESARIOS EJECUTE ESTAS 3 LINEAS
para.instalar <- c("knitr","gridExtra","ggplot2","party","strucchange","sandwich","zoo",
  "stats4","grid","modeltools","stats","graphics","grDevices","utils","datasets",
  "mvtnorm","methods","base","tm","wordcloud","RColorBrewer","ggplot2","NLP","graphics",
  "fpc","grDevices","SnowballCC","biclust","cluster","igraph","Rcpp","topicmodels","NMF")

install.packages(para.instalar, dependencies=TRUE)
install.packages("Rcampdf", repos = "http://datacube.wu.ac.at/", type = "source")
```

ANALISIS EXPLORATORIO

En el notebook iPython adjunto (*../reports/PRELIMINAR.html*) se puede ver un analisis exploratorio de más de 32.000 archivos que los usuarios depositan en un directorio tras leerlos y etiquetarlos. Para visualizar el código se puede pulsar el botón “VER CÓDIGO” o abrir el propio código Python alojado en la carpeta *code*: (*../code/PRELIMINAR.ipynb*).

Los datos se obtienen con un volcado del comando **ls** a CSV. Con excel operamos para quedarnos con la extension, tamaño, fecha y etiqueta que han insertado en el nombre los diferentes departamentos al clasificar. Se adjunta dicho excel procesado en la misma carpeta que esta memoria (*data/procesados.xls*):

Para ajustarse a la situación más reciente posible, obtenemos un CSV con frecuencias por tipo de documento de un día actual con documentos sin procesar.

```
#!/bin/bash
ls | awk -F . '{print $NF}' | sort | uniq -c | awk '{print $2,$1}' > files.csv
```

VISUALIZACIÓN DE FRECUENCIAS


```
rm(list=ls())
```

```
library(plyr); library(knitr)
files <- read.table("../data/files.csv", header = F)
files <- rename(files,c("V1"="type", "V2"="frequency"))
files <- files[2:nrow(files),] # elimina primera fila (el directorio)
```

```
kable(files)
```

	type	frequency
2	doc	34
3	DOC	116
4	pdf	986
5	PDF	18
6	rtf	127
7	RTF	71

Nótese que la capitalización de las extensiones hace que detecte archivos del mismo formato como si fuesen distintas clases de archivo. En el notebook que analiza la carpeta de archivos ya procesados no aparece este hecho. Se tendrá en cuenta para más adelante.



PLANTEAMIENTO INICIAL DEL FLUJO DE TRABAJO

1. Extracción del texto de los archivos tipo DOC y RTF.
2. Extracción del texto de los documentos PDF.
3. Extracción y recuento de palabras específicas solicitadas por cada departamento.
4. Clasificación de los documentos.

EXTRACCIÓN DE TEXTO

RTF Y DOC

Se opta por usar la línea de comandos de LibreOffice en lugar de **catdoc** o **unrtf** (daban problemas con imágenes embebidas), que además es extremadamente más rápido que estos últimos.

El proceso es gestionado por el script de bash en el servidor (**code/extraccion.sh**). Dicho script se encarga de generar los directorios de trabajo necesarios, clasificar los documentos, abrirllos, extraer la información, obtener imágenes si existen, etcétera.

El mismo script se encarga de que todo deje registro en un log, generar tablas CSV con parámetros y metadatos de documento, llevar contabilidad para un informe final del proceso (**data/summary.log**) y medir los tiempos consumidos por cada fase.

Se recomienda abrirlo con un editor de código para ver el proceso en detalle de manera paralela a esta memoria.

Ejemplo de extracción de texto en archivo WORD

```
#!/bin/bash

libreoffice --invisible --norestore --convert-to txt:"Text" --headless $word_file \
--outdir "${OUTPUT}"/processed"
```

PDF

Los PDF están constituidos en ocasiones por imágenes. Siendo necesario abrirllos manualmente uno a uno para saberlo.

En caso afirmativo, para una correcta extracción del contenido, se hace necesario realizar un reconocimiento óptico de caracteres (OCR). Sin embargo, el OCR es muy costoso en tiempo y recursos. En pruebas iniciales con 400 pdf el proceso OCR tardó 3 días en completarse (1 core, 4 GB Ram).

Para analizar los PDF, mediante herramientas del sistema operativo (**poppler-utils**) se genera un CSV con metadatos de cada uno de ellos. Entre otros y sin ser exhaustivos:

- Número de imágenes (IMAGES), fuentes incrustadas (FONTS) y rotación de página (ROTATION).
- Líneas en primera página (FIRSTPAGELINES), numero total de palabras (TWORDS) y palabras en segunda página (PAGELINESSECOND).
- Frecuencia de las tres palabras más comunes en castellano según la RAE :de|la|que en primera página (FWORDS1).

Link al corpus de la RAE

Ejemplo de obtención de metadatos del PDF

En un bucle **for** que recorra todos los ficheros **\$pdf_file**:

```
#!/bin/bash

# limpiar todos los caracteres extraños con expresiones regulares
firstpage="$$(pdftotext -f 1 -l 1 -enc UTF-8 "$pdf_file" - | tr -cd \
'[:alnum:]] [áéíóúÁÉÍÓÚñÑªºüÛ°;]\40-\40\045\054\011\012\014\015\057\050\051\100\056' \
| sed '/^$/d' | sed 's/^[[:print:]]/ /g')

firstpagelines="$$(echo "$firstpage" | wc -l) # líneas de primera pagina

fwords="$$(echo "$firstpage" | grep -E de\|la\|que | wc -l) # 3 mas frecuentes español

fonts="$$(pdffonts "$pdf_file" | wc -l) # número de fuentes incrustadas

imagesp="$$(pdftimages -list "${pdf_file}" | wc -l) # número de imágenes incrustadas
```

PRIMERAS HIPÓTESIS

Las primeras hipótesis de trabajo analizando los metadatos PDF son:

- Documentos sin fuentes incrustadas indican que están compuestos de imágenes escaneadas (dimensión *fonts*).
- Documentos con muchas imágenes incrustadas indican igualmente la ausencia de texto parseable (dimensión *images*).
- Documentos que en primera página no cuentan con ninguna de las palabras más frecuentes en castellano son igualmente constituidos de imágenes (dimensión *fwords1*).
- Lo mismo reza para aquellos con escasas líneas en la primera página (dimensión *firstpagelines*).

Para tener un volumen suficiente de documentos se solicita a las personas que los leen a diario, que al cerrarlos los renombren poniendo si son texto o imagen. Ante la duda o mezcla de ambos contenidos se etiquetan por defecto como imagen para forzar el OCR.

Con su ayuda al cabo de un tiempo disponemos de más de 400 documentos etiquetados para comenzar a probar.

CLASIFICACIÓN PRELIMINAR: Texto/Imagen

Con el CSV de los metadatos se realiza un primer análisis exploratorio. Preparemos los datos para ver las correlaciones:

```
pdf.metadata <- read.csv("../data/pdf_metadata.csv", sep=";", strip.white=TRUE)

# descartar el nombre del archivo. Para clasificación NO es util
tmp <- pdf.metadata[, !(colnames(pdf.metadata) %in% ("FILE"))]
```

```
# En la correlación logística solamente hay 5 variables significativas
```

```
# LA SALIDA DE ESTE COMANDO SE OMITE POR BREVEDAD
```

```
fit <- glm(TIPO ~ . , data = tmp, family=binomial)
```

```
summary(fit)
```

CORRELACIÓN

```
fit<-glm(TIPO ~ IMAGES + ROTATION + PAGELINESSECOND + FWORDS1 + TWORDS1,data=tmp,
        family=binomial)

# summary(fit) # solo las variables que son significativas
tmp <- tmp[,c("TIPO","IMAGES","ROTATION","PAGELINESSECOND","FWORDS1","TWORDS1","FONTS")]
```

Coefficients	Estimate	Std. Error	z value	Pr(>z)	signif.
(Intercept)	2.6857962	0.2633980	10.197	< 2e-16	***
IMAGES	0.0008252	0.0003182	2.593	0.0095	**
ROTATION	0.0142835	0.0082926	1.722	0.0850	.
PAGELINESSECOND	-0.0822938	0.0116167	-7.084	1.40e-12	***
FWORDS1	-0.2120895	0.0493709	-4.296	1.74e-05	***
TWORDS1	-0.0059823	0.0030149	-1.984	0.0472	*

VISUALIZACIÓN DE DENSIDAD EN DIMENSIONES

```
library(ggplot2) ; library(gridExtra)


g.images <- ggplot(tmp, aes(IMAGES, fill = TIPO, colour = TIPO)) +
  geom_density(alpha = 0.6) + ggtitle("Número de Imágenes") +
  theme(axis.title.x=element_blank()) + xlim(0.20,250)

g.rotation <- ggplot(tmp, aes(ROTATION, fill = TIPO, colour = TIPO)) +
  geom_bar(alpha = 0.6) + ggtitle("Rotación de página") +
  theme(axis.title.x=element_blank())

g.pag12 <- ggplot(tmp, aes(PAGELINESSECOND, fill = TIPO, colour = TIPO)) +
  geom_density(alpha = 0.6) + ggtitle("Líneas de texto en 2ª pág.") +
  theme(axis.title.x=element_blank()) + xlim(1,100)

ocr <- subset(tmp, TIPO=="ocr") ; txt <- subset(tmp, TIPO=="txt")
g.fwords1 <- ggplot(tmp, aes(FWORDS1, fill = TIPO, colour = TIPO), main = "RAE") +
  geom_density(alpha = 0.6) + theme(axis.title.x=element_blank()) +
  ggtitle("Frecuencias Corpus RAE")

library(gridExtra)
grid.arrange(g.images, g.rotation, g.pag12, g.fwords1, ncol=2, nrow =2)
```



PALABRAS, FUENTES y ALGO MÁS

```
tmp2 <- pdf.metadata[,c("TIPO", "TWORDS1", "FONTS", "PAGELINESFIRST", "PAGELINESLAST")]

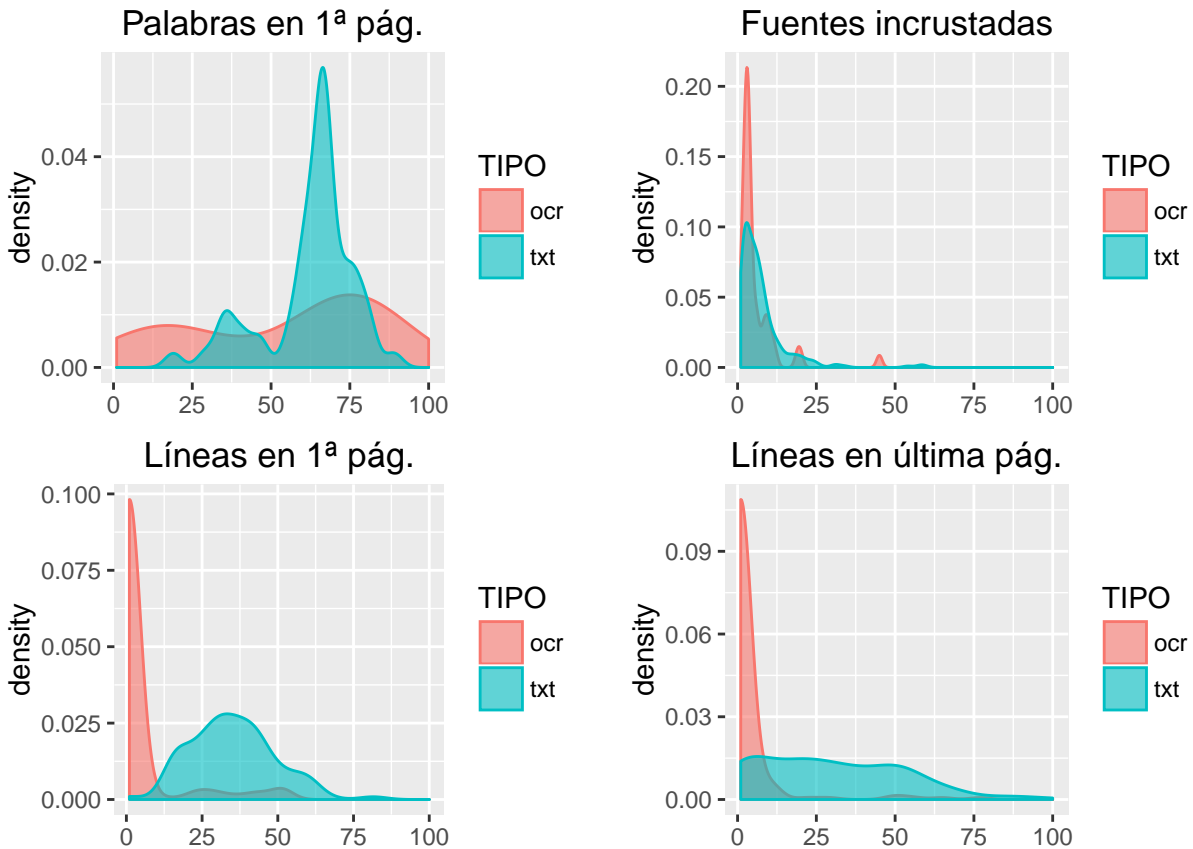
g.words1 <- ggplot(tmp2, aes(TWORDS1, fill = TIPO, colour = TIPO)) +
  geom_density(alpha = 0.6) + ggtitle("Palabras en 1ª pág.") +
  theme(axis.title.x=element_blank()) + xlim(1,100)

g.fonts <- ggplot(tmp2, aes(FONTS, fill = TIPO, colour = TIPO)) +
  geom_density(alpha = 0.6) + ggtitle("Fuentes incrustadas") +
  theme(axis.title.x=element_blank()) + xlim(1,100)

g.pg11 <- ggplot(tmp2, aes(PAGELINESFIRST, fill = TIPO, colour = TIPO)) +
  geom_density(alpha = 0.6) + ggtitle("Líneas en 1ª pág.") +
  theme(axis.title.x=element_blank()) + xlim(1,100)

g.pglast <- ggplot(tmp2, aes(PAGELINESLAST, fill = TIPO, colour = TIPO)) +
  geom_density(alpha = 0.6) + ggtitle("Líneas en última pág.") +
  theme(axis.title.x=element_blank()) + xlim(1,100)

grid.arrange(g.words1, g.fonts, g.pg11, g.pglast, ncol=2, nrow=2)
```



De modo general, cuando el PDF requiere OCR, hay mayor densidad (frecuencia) en cada variable en torno al valor cero. Con la excepción de las dimensiones IMAGES, ROTATION, FONTS y TWORDS1.

ÁRBOL DE CLASIFICACIÓN

```
library(party)

tmp3 <- pdf.metadata[, !(colnames(pdf.metadata) %in% ("FILE"))]

arbol.ct<-ctree(TIPO ~ IMAGES+ROTATION+PAGELINESSECOND+FWORDS1+TWORDS1+FONTS+PAGES+SIZE,
               data=tmp3)

reales.ct <- tmp3$TIPO

predichos.ct<- predict(arbol.ct)

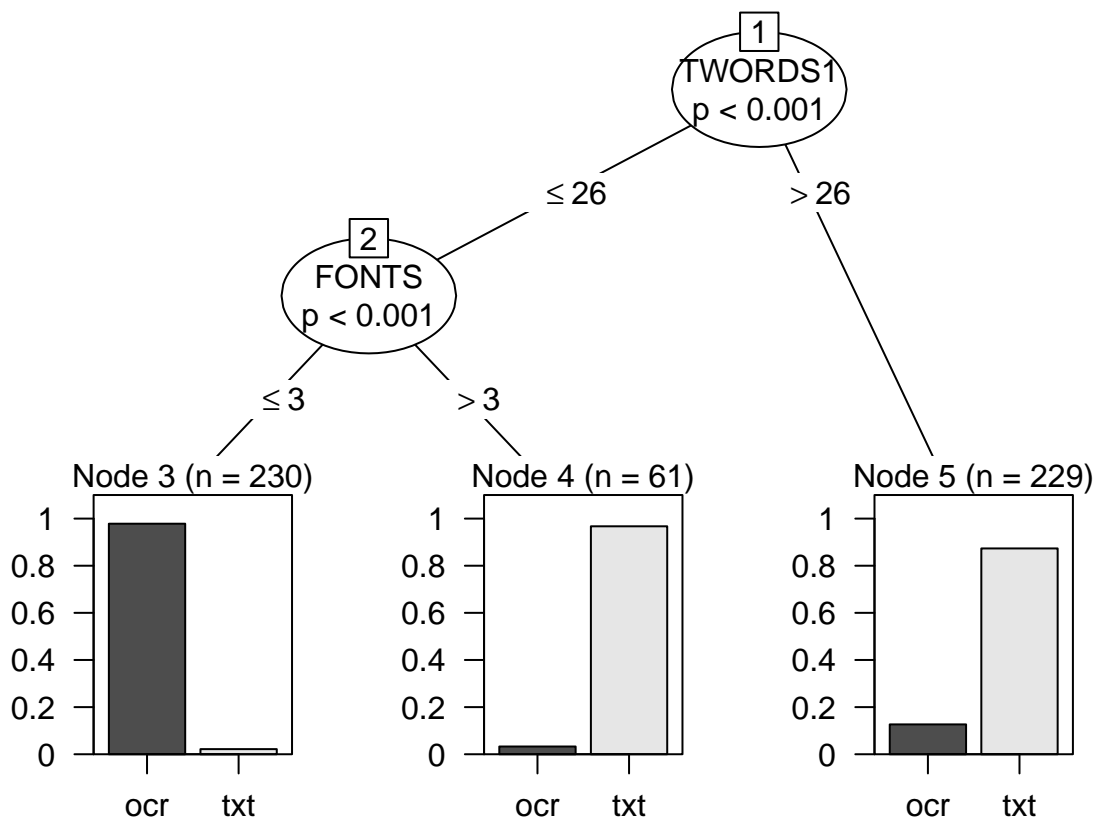
confusion <- table(reales.ct, predichos.ct)

kable(confusion)
```

	ocr	txt
ocr	225	31
txt	5	259

En términos generales se confirman las sospechas. Los documentos para OCR tienen pocas fuentes incrustadas, pocas palabras, muchas imágenes y no poseen los 3 vocablos más frecuentes del Español en su primera página. Sin embargo, deberá tenerse en cuenta que algunos de ellos son calificados como texto (ver matriz de confusión)

```
plot(arbol.ct, tp_args = list(beside = TRUE))
```



PUNTO DE CORTE

Sabido lo anterior, se define en el bash script **extraccion.sh** (líneas 310 a 364) la clasificación preliminar de los documentos con una mezcla de sentido común y de los indicios del árbol de la siguiente forma:

- Más de 20 páginas obliga a lectura (requisito de negocio). Se mueve a directorio *rejected*
- Fuentes incrustadas menor o igual a 1: se mueve a directorio *pdf_ocr*
- Menos de 3 en el conteo de 3 palabras más frecuentes en Español según RAE: a directorio *pdf_ocr*
- Más imágenes que páginas: se mueve a directorio *pdf_ocr*
- Más de 20 líneas de texto en primera página : se mueve a directorio *pdf_txt*

Como aún así es posible que algún PDF quede sin procesar, en las líneas 22-46 del script *code/resumen_juridico.sh* se comprueba que todos los textos extraídos tengan contenido.

En tal caso se guarda el nombre del archivo en un log y se mueve a la carpeta *non processed* para revisión posterior al finalizar la ejecución del proceso. Puede ser interesante investigar qué tipo de archivos escapan a la conversión.

Gestión de ficheros vacíos. Primero comprobamos si tienen contenido, y si no es así se mueven.

```
#!/bin/bash
if [ "$en_documento" == 0 ];then

nombrepdf=$(basename $f .txt)".pdf"

nombresinext=$(basename $f .txt)

mv $f ../non_processed/

    if [ -f "${OUTPUT}"/pdf_ocr/"${nombrepdf} ]; then # si estaba clasificado como OCR
        mv "${OUTPUT}/pdf_ocr/"${nombrepdf} ../non_processed/
    fi

    if [ -f "${OUTPUT}"/pdf_txt/"${nombrepdf} ]; then # si estaba clasificado como TXT
        mv "${OUTPUT}/pdf_txt/"${nombrepdf} ../non_processed/
    fi

    echo $f >> "${OUTPUT}"/error.log"
fi
```

Una vez clasificados los PDF como “txt” o como “ocr” se pasa a extraer el contenido mediante *pdftotext* en el primer caso, y usando una combinación de *convert* (extrae las imágenes) y *tesseract* (realiza el OCR) en el segundo. En pruebas iniciales este proceso se revela extremadamente lento. Por ello con GNU Parallel lanzamos un hilo por cada nucleo del procesador (parámetro obligatorio **THREADS**).

Ejemplo de extracción de contenido en pdf compuesto por texto

```
#!/bin/bash

pdftotext -enc UTF-8 "$pdf_file" "${OUTPUT}/processed/${FILENAMESinPDF}.txt
```

Ejemplo de extracción multihilo en pdf compuesto por imágenes escaneadas (GNU Parallel)

```
#!/bin/bash

# convert (extrae imágenes del PDF)

find . -name '*.pdf' | parallel -j ${THREADS} --progress convert -density 600 -trim {} \
-quality 100 -set filename:f '%t' '../tmp/${basename '{}'.pdf}'__%03d.jpg

# tesseract (ocr a los jpg extraídos)

find . -name '*.jpg' | parallel -j ${THREADS} --progress tesseract {} \
-l spa '${basename '{}'.jpg}'
```

Se obtiene como resultado del anterior proceso:

- Una imagen por cada página del documento.
- Un fichero de texto plano con el contenido interpretado mediante OCR por cada imagen del paso anterior.

Ahora se debe por tanto concatenar cada uno de los ficheros de texto en el mismo orden en que se lee en el PDF original.

Concatenado de los ficheros de texto con nombre del PDF original:

```
#!/bin/bash

for tt in "../tmp/"$(echo $nombrebase | sed -e 's/[]/?/g') #para cada fichero de texto
do
    FINALTXTNAME=$(echo ${nombrebase} | sed -e 's/\*///g') #capturamos nombre de PDF "padre"

    cat $tt | sed 's/\o14//g' | tr -cd '\11\12\15\40-\176' | sed '1 s/\xEF\xBB\xBF/' \
    | sed '/^$/d' | sed 's/[[:print:]]/ /g' | sed 's/-//g' | sed 's/_\. _//g' \
    | sed 's/"/"/g' | sed 's/_\._//g' | sed 's/"/"/g' | sed "s/'/'/g" \
    >> ${OUTPUT}"/processed/"${FINALTXTNAME}

    rm -f $tt # borramos todos los textos "hijo"
done
```

PÉRDIDA DE INFORMACIÓN

Es esperable cierto grado de pérdida de información en el proceso OCR. Máxime cuando los archivos de origen son malas copias de un original, tienen tachaduras o escrituras a mano, imágenes torcidas, etc.

Para poder tener alguna idea de esta magnitud, se extrae un valor numérico de la pérdida sufrida, pasando el texto resultante por un diccionario (*aspell*_es) y computando el número de palabras que no se hallan en él.

Es una estimación muy burda, pues cosas como los nombres propios no se encontrarán, pero sirve al propósito de informar del ratio de pérdida de manera consistente para todos los documentos.

$$perdida = \frac{totalNOencontradasendiccionario}{totalpalabrasendocumento}$$

```
#!/bin/bash
for t in *.txt
do
    en_documento=$(cat "$t" | wc -w) # contamos el total de palabras
    no_en_diccc=$(cat "$t" | aspell list | sort -u -f | wc -l) # aspell
    perdida=$(echo "scale=2;$no_en_diccc / $en_documento" | bc -l) # ratio calculado
    echo "$t tiene una pérdida de $perdida"
done
```

EXTRACCIÓN DE PALABRAS ESCOGIDAS

Cada departamento saca conclusiones y toma decisiones en base al contenido de cada pdf.

En reuniones mantenidas a tal efecto, se recoge una lista de palabras clave que, según su experiencia, les ayuda a clasificar y decidir la importancia de cada documento.

Esta lista de palabras se incorpora a un script separado por cada departamento que se cargará (o no) en función del parámetro obligatorio de entrada STYPE (líneas 465-469 del bash script **extraccion.sh**)

Este script realiza un parseo del texto por expresiones regulares, contabilizando tanto palabras sueltas como agrupadas, e incluso realizando una extracción tentativa de textos más complejos a un CSV.

IMPORTANTE:

El citado script se aporta a modo de ejemplo aunque los textos a parsear se han sustituido por motivos de confidencialidad.

RESULTADOS PRELIMINARES Y FEEDBACK

El resultado de este primer tramo, genera una serie de directorios con los documentos clasificados según el proceso sufrido, y un archivo csv donde se reflejan la pérdida de la conversión y el total de palabras de cada uno de ellos: data/accuracy.csv

Se muestran unas líneas:

DOCUMENTO	PERDIDA	PALABRAS
F001	.22	211
F002	1	0
F003	.13	212
F004	.17	60
F005	.04	168
F006	.05	212

El feedback de los diferentes departamentos es muy positivo, llevando procesados hasta el momento más de 25.000 documentos mediante este sistema desde la puesta en marcha.

Las mejoras en los tiempos son evidentes, pasando en el caso más exitoso, de una lectura/procesado promedio de 150 documentos a la semana, a más de 3.000 en el mismo periodo de tiempo.

Los usuarios solamente acuden al documento original cuando la pérdida de información en el proceso supera el 15%. Para todo lo demás, operan sobre el CSV que contiene los resultados, con verificaciones ocasionales que hasta el momento no han informado de problemas.

Tanto es así, que se han asignado más recursos materiales al proyecto, y el hardware inicial, bastante limitado por ser una prueba piloto, ha escalado verticalmente y se dispone ahora de 4 veces más capacidad de proceso, habiéndose reducido los tiempos de la fase de cómputo a una cuarta parte.

CLASIFICACIÓN POR CONTENIDOS

UNOS PASOS MÁS

Se aprovecha este éxito inicial, para intentar ir un paso más allá y realizar una clasificación por temas.

El primer problema encontrado es, que aquellos pdf de mala calidad, tras el OCR generan un archivo de texto con muchas palabras que no corresponde con palabras reales.

Algunas de esas palabras son comprensibles aunque serían rechazadas por un diccionario (procurador ~ procurader). Por desgracia, ni *aspell* ni otros sistemas probados ofrecen una corrección automática.

De modo que, esta vez se usa *aspell* para generar un listado completo de palabras no aceptadas, que posteriormente se revisarán para apreciar el éxito del OCR más allá del cálculo numérico de pérdida.

```
#!/bin/bash
# volcar todas las palabras que no están en el diccionario a un archivo
for file in *.txt
do
    cat "$file" | tr '\n\r' ' ' | aspell list | sort -u -f >> base_stopwords.txt
done

# Orden por frecuencias únicas descendentes y revisar
cat base_stopwords.txt | sort | uniq -c | sort -nr > cleaning_stopwords.txt
```

RESULTADO (muestra)

```
#!/bin/bash
cat stopwords.txt
1249 ña
1198 ENJ
1188 Ia
1165
1156 Not
1156 Hash
1144 Pérez
1120 Álvaro
1112 OF
1106 pdf
992 II
989 Io
987 ei
981 ll
880 INST
```

DECISIÓN

Se puede ver que las mayores frecuencias son artefactos del OCR o nombres propios. Por tanto se decide dejar los textos tal cual pero seleccionar para la clasificación aquellos con más de 5 líneas y un máximo del 15% de pérdida. Este proceso se ejecuta mediante el bash script ../code/cleaner.sh

```
#!/bin/bash
for f in *.txt
do
    lineas="$(cat "$f" | wc -l)"

    if [ "$lineas" -gt 5 ]; then # más de 5 líneas

        # solamente letras, numeros, espacios y separador de nueva linea
        limpio="$(cat $f | tr -cd '[:alnum:][áéíóúÁÉÍÓÚñÑªºüÜ°;-]\040\012' | sed '/^$/d' )"

        en_documento=$(echo "$limpio" | wc -w) # total de palabras
        no_en_dicc=$(echo "$limpio" | aspell list | sort -u -f | wc -l) # aspell inverso
        perdida=$(echo "($no_en_dicc / $en_documento)*100" | bc -l) # ratio
```

```

    if (( $(echo "$perdida < 15"|bc -l) )) ;then
        echo "$limpio" > cleaned/$f
    fi
fi
done

```

DOCUMENT TERM MATRIX

Procedemos a generar la matriz de documentos necesaria con el paquete tm sobre los documentos escogidos en el anterior paso en caso de que nos fuera necesaria mayor precisión.

```

library(tm)

# lectura del directorio de documentos (no aportado)
files <- DirSource(directory = "../documentos/",encoding ="UTF-8" )
docs <- VCorpus(x=files)

# transformaciones aplicadas al corpus
docs <- tm_map(docs, content_transformer(removePunctuation))
docs <- tm_map(docs, content_transformer(tolower))

docs <- tm_map(docs, removeWords,c("maria","garcia","jose",
                                   "julio","manuel","juan",
                                   "martinez","alvaro","perez"))

docs <- tm_map(docs, removeWords, stopwords("spanish"))
docs <- tm_map(docs, content_transformer(removeNumbers))

# el proceso elimina la barra que separa géneros en la palabra abogado: se hace corrige
docs<-tm_map(docs,content_transformer(function(x)stri_replace_all_fixed(x,"abogadoa",
                                                                           "abogado",vectorize_all=FALSE)))

docs <- tm_map(docs, content_transformer(stripWhitespace))

# creación de la matriz DTM
dtm <- DocumentTermMatrix(docs)
dtm <- removeSparseTerms(dtm, 0.9)

# Vamos a preservar el contenido de la matriz en disco para uso posterior
matriz <- as.matrix(dtm)
# pasamos a Data Frame
df <- as.data.frame(matriz)
# dar nombre a la columna rownames (index)
df <- cbind(FILENAMES = rownames(df), df)
# nos deshacemos de la rownames original
rownames(df) <- NULL
# escribimos a disco
write.csv(df, file="../data/df_dtm.csv", sep = ";")

```

WORD CLOUDS

extraemos la nube de palabras de los cuatro tipos de documentos existentes

```
library(wordcloud)
```

```
freq <- colSums(as.matrix(dtm))
set.seed(1234)
wordcloud(names(freq), freq,min.freq=10, random.order=FALSE, rot.per=.20,
           colors=brewer.pal(8,"Dark2"))
```



TOPIC MODEL

generamos el topic model para el conjunto de todos los documentos mezclados
asignamos al parámetro k el número de topics deseado (4)

```
library(topicmodels)
```

```
burnin <- 4000
iter <- 2000
thin <- 500
```

```
seed <-list(2003,5,63,100001,765)
nstart <- 5
```

[illegible]

CLUSTERS MEDIANTE KMEANS

```
library(fpc)

d <- dist(t(dtm), method="euclidian")

kfit <- kmeans(d, 4)

clusplot(as.matrix(d), kfit$cluster, color=T, shade=T, labels=2, lines=0, main="CLUSTER KMEANS")

# parece haber 4 temas claramente diferenciados de los cuales 2 tienden a solaparse
```

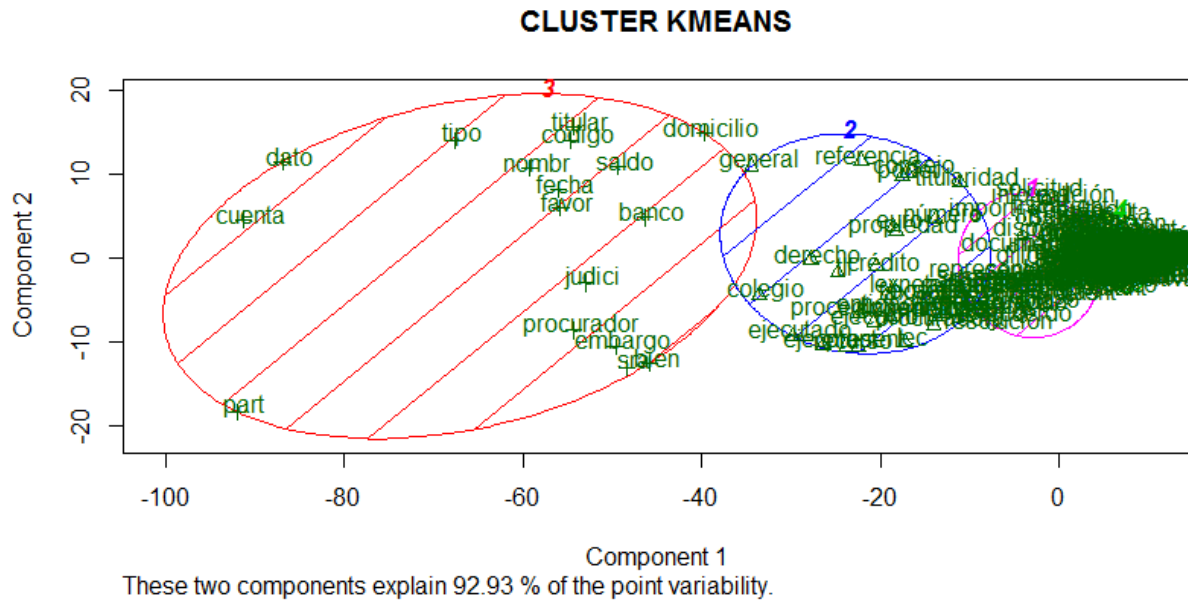


Figure 1:

TÉRMINOS MÁS FRECUENTES POR TEMA

```
ldaOut@terms
Terms <- terms(ldaOut, 10)
```


Los 10 primeros términos para cada uno de los cuatro temas generados.

```
library(knitr)
load("../data/temas.Rdata")
temas <- as.data.frame(temas)

kable(temas)
```

Topic 1	Topic 2	Topic 3	Topic 4
bien	part	procurador	cuenta
embargo	sra	part	dato
ejecutado	present	juzgado	fecha
ejecutant	posición	ejecución	judici
sra	juicio	instancia	tipo
depósito	judici	fax	nombr
recurso	banco	primera	banco
entidad	plazo	notificación	saldo
mejora	secretario	procedimiento	código
deberá	procedimiento	justicia	general

PREDICCIÓN DE TEMAS

```
library(party)
library(knitr)

# carga del CSV con los contenidos del dataframe de la DTM (disponible en carpeta data)
dtm.df <- read.csv("../data/df_dtm.csv", sep=";", stringsAsFactors=FALSE)

# Extraemos a un campo nuevo la etiqueta del tipo de documento
# está inserta en el nombre entre el guión bajo y la extensión

inicio <- regexpr('[_]',dtm.df$FILENAMES)+1
fin <- regexpr('[.]',dtm.df$FILENAMES)-1

dtm.df$LABEL <- substring(dtm.df$FILENAMES, inicio , fin)

table(dtm.df$LABEL)
```

```
##
##      APROBACION NOTIFICACIONES      ORDENAMIENTO      OTROS
##           294           140           58           28
```

```
# descartar el nombre del archivo. Para clasificación NO es util
res <- dtm.df[, !(colnames(dtm.df) %in% ("FILENAMES"))]

res$LABEL<-as.factor(res$LABEL)

# guardamos a disco el nuevo data frame
write.csv(res, file="../data/resultado.csv", sep = ";")
```

```
## Warning in write.csv(res, file = "../data/resultado.csv", sep = ";"):
## attempt to set 'sep' ignored
```

```
arbol.temas <- ctree(res$LABEL ~ ., data = res)

reales.temas <- res$LABEL

predichos.temas <- predict(arbol.temas)

# MATRIZ DE CONFUSIÓN
temas.confusos <- table(reales.temas, predichos.temas)

kable(temas.confusos)
```

	APROBACION	NOTIFICACIONES	ORDENAMIENTO	OTROS
APROBACION	289	0	2	3
NOTIFICACIONES	8	128	1	3
ORDENAMIENTO	8	2	48	0
OTROS	7	6	4	11

```
# plot del árbol de temas
# ATENCIÓN: por su tamaño, el CTREE no logra verse completo al detalle
# se adjunta en alta resolución en la carpeta ../plots/arbol_temas.png
```

```
plot(arbol.temas, tp_args = list(beside = TRUE))
```




Figure 2:

A partir de las indicaciones de este último árbol se implementa un script (`../code/clasificador.sh`) que vuelca a CSV (`../data/predictivo_temas.csv`) la clasificación obtenida.

Este CSV se ha entregado a los correspondientes departamentos para que cotejen su fiabilidad.

```
#!/bin/bash
```

```
contiene_mejora="$$(echo "$CONTENIDOF" | grep -E -i -o -c '\bmejora\b')
contiene_general="$$(echo "$CONTENIDOF" | grep -E -i -o -c '\bgeneral\b')
contiene_embargo="$$(echo "$CONTENIDOF" | grep -E -i -o -c '\bembargo\b')
contiene_consulta="$$(echo "$CONTENIDOF" | grep -E -i -o -c '\bconsulta\b')
tema_detectado="desconocido"
```

```
# clasificación por contenido extraída a partir de arbol de inferencia con R
```

```
if [ $contiene_mejora -gt 0 ]; then

    tema_detectado="NOTIFICACIONES"

else

    if [ $contiene_general -gt 2 ]; then

        tema_detectado="ORDENAMIENTO"

    else

        if [ $contiene_embargo -gt 2 ]; then

            tema_detectado="OTROS"

        else

            if [ $contiene_consulta -gt 0 ]; then

                tema_detectado="ORDENAMIENTO"

            else

                if [ $contiene_embargo -gt 0 ]; then

                    tema_detectado="APROBACION-NOTIFICACIONES-OTROS"

                else

                    tema_detectado="APROBACION"

                fi

            fi

        fi

    fi

fi

fi

fi
```

```
library(knitr)
# carga del CSV con los contenidos del csv predictivo_temas (disponible en carpeta data)
predictivo.temas <- read.csv("../data/predictivo_temas.csv", sep="^",
                             stringsAsFactors=FALSE)

# muestra de los contenidos
kable(head(predictivo.temas))
```

DOCUMENTO	PREDICCION	MEJORA	GENERAL	EMBARGO	CONSULTA
F001	APROBACION-NOTIFICACIONES-OTROS	0	1	1	0
F002	APROBACION	0	1	0	0
F003	NOTIFICACIONES	3	2	5	0
F004	NOTIFICACIONES	3	1	5	0
F005	APROBACION	0	0	0	0
F006	APROBACION	0	0	0	0

Mientras los departamentos correspondientes van evaluando la idoneidad de este modelo sencillo, se prosigue en la búsqueda del modelo predictivo más ajustado. Entre otras cosas, se ha mejorado la lectura de datos y la generación de modelos con las siguientes inclusiones:

1. Diferentes modos de generar las rutas según si la máquina es Linux o Windows
2. Comprobación previa de la existencia del objeto antes de generarlo

Para ello vamos a probar con diferentes procedimientos.

El siguiente código realiza la predicción mediante los siguientes modelos.

ATENCION : datos no incluidos por confidencialidad.

- Ctree
- Evolutionary tree
- Knn
- Jackknife
- Random forest
- Naive-Bayes
- Support Vector Machine
- Gradient Boosting Machine

```
# limpieza de memoria
rm(list=ls(all=TRUE))

# usamos pacman para gestionar la instalacion y carga de los paquetes necesarios
if (!require("pacman")) install.packages("pacman")
pacman::p_load(profvis, tm, party, stringi, evtree, caret, e1071, randomForest, class, gbm)

# obtenemos el directorio dado que hay diferencias entre los entornos windows y linux
so <- .Platform$OS.type
```

```

if (so == "windows"){

  directorio <- file.path("~", "CODIGO", "R", "documentos")
  datafolder <- file.path("~", "CODIGO", "datos", "documentos")

} else {

  directorio <- file.path("~", "scripts", "R", "documentos")
  datafolder <- file.path("~", "scripts", "datos", "documentos")

}

setwd(directorio)

# cargamos los datos del modelo guardados.
# Si no han sido guardados se generan de nuevo

archivo.datos <- file.path(directorio, "modeldata.rda")

if(file.exists(archivo.datos)) {

  load(archivo.datos)

} else {

  # fuente de los textos
  txt.files <- DirSource(directory = datafolder, encoding = "UTF-8" )
  docs <- VCorpus(x=txt.files)

  # transformaciones aplicadas al corpus
  docs <- tm_map(docs, content_transformer(removePunctuation))
  docs <- tm_map(docs, content_transformer(tolower))

  docs <- tm_map(docs, removeWords, c("maria", "garcia", "jose",
                                     "julio", "manuel", "juan",
                                     "martinez", "alvaro", "perez"))

  docs <- tm_map(docs, removeWords, stopwords("spanish"))
  docs <- tm_map(docs, content_transformer(removeNumbers))

  # el proceso elimina la barra que separa géneros en la palabra abogado: se hace corrige
  docs <- tm_map(docs, content_transformer(function(x) stri_replace_all_fixed(x, "abogadoa",
                                                                              "abogado", vectorize_all=FALSE)))

  docs <- tm_map(docs, content_transformer(stripWhitespace))

  # creación de la matriz DTM
  dtm <- DocumentTermMatrix(docs)
  dtm <- removeSparseTerms(dtm, 0.9)

  # serializar
  m <- as.matrix(dtm)
  df <- as.data.frame(m)

```

```

# filename como columna
df <- cbind(FILENAMES = rownames(df), df)
rownames(df) <- NULL

# obtencion de la etiqueta entre el guion bajo y la extension
inicio <- regexpr('[_]',dtm.df$FILENAMES)+1
fin <- regexpr('[.]',dtm.df$FILENAMES)-1

dtm.df$LABEL <- substring(dtm.df$FILENAMES, inicio , fin)

# subsetting de todo menos el nombre de fichero
res <- df[,-1]
res <- res[,c(ncol(res),1:(ncol(res)-1))]
res$LABEL <- as.factor(res$LABEL)

# convertimos a factor la etiqueta
res$LABEL <- factor(res$LABEL)

# salvamos
save(res, file = "modeldata.rda")

}

```

PROBANDO MODELOS PREDICTIVOS

En todos los casos el procedimiento es el mismo:

Si no se encuentra el fichero con las predicciones, se genera. Si existe, se carga en memoria.

**** Este código se encuentra en el archivo code/modelos.R ****

Ctree

```

archivo.ctree <- file.path(directorio,"ctree.rda")

if(file.exists(archivo.ctree)) {

  load(archivo.ctree)

} else {

  arbol.juridico <- ctree(res$LABEL ~ ., data = res)

  save(arbol.juridico, file = "ctree.rda")
}

pred.ctree <- predict(arbol.juridico, res, savePredictions = TRUE)

```

Evolutionary tree

```
archivo.evotree <- file.path(directorio,"evotree.rda")

if(file.exists(archivo.evotree)) {
  load(archivo.evotree)
} else {

  fit <- evtree(LABEL ~ . , data=res)
  save(fit, file = "evotree.rda")
}

pred.evo <- predict(fit ,type ="response", savePredictions = TRUE)
```

Knn

```
archivo.knn <- file.path(directorio,"modeloknn.rda")

if(file.exists(archivo.knn)) {

  load(archivo.knn)
} else {

  entreno2 <- trainControl(method = "knn",
                           number = 10, savePredictions = TRUE)
  grid2 <- expand.grid(k = 1:10)
  modeloknn <- train(LABEL ~ . , data = res)
  save(modeloknn, file = "modeloknn.rda")
}

pred.knn <- predict(modeloknn, res, savePredictions = TRUE)
```

Jackknife

```
archivo.jackknife <- file.path(directorio,"jackknife.rda")

if(file.exists(archivo.jackknife)) {

  load(archivo.jackknife)
}else{

  pred.jackknife <- knn.cv(res[,-1], res$LABEL, k = 1)
  save(pred.jackknife, file = "jackknife.rda")
}
```

Random forest

```
archivo.rf <- file.path(directorio,"randomforest.rda")

if(file.exists(archivo.rf)) {

  load(archivo.rf)

} else {

  rf <- randomForest(LABEL ~ ., data = res, ntree = 500)
  save(rf, file = "randomforest.rda")
}

pred.rf <- rf$predicted
```

Naive-Bayes

```
archivo.naive <- file.path(directorio,"naivebayes.rda")

if(file.exists(archivo.naive)) {

  load(archivo.naive)

} else {

  model.nb <- naiveBayes(LABEL ~., data = res,res$LABEL)
  save(model.nb, file = "naivebayes.rda")

}

pred.nb <- predict(model.nb,res[,-1])
```

Support Vector Machine

```
archivo.svm <- file.path(directorio,"svm.rda")

if(file.exists(archivo.svm)) {

  load(archivo.svm)

} else {

  mod.svm <- svm(LABEL ~ ., data = res, kernel = "radial")
  save(mod.svm, file = "svm.rda")
}

pred.svm <- mod.svm$fitted
```


Gradient Boosting Machine

```
archivo.gbm <- file.path(directorio,"gbm.rda")

if(file.exists(archivo.gbm)) {

  load(archivo.gbm)

} else {

mod.gbm <- gbm(LABEL ~ ., data = res, interaction.depth = 6, n.trees= 10000, cv.folds = 3)
save(mod.gbm, file = "gbm.rda")
}

perf <- gbm.perf(mod.gbm, method = "cv")
# probabilidad arbitraria de falso mayor de 0.5
table(res$LABEL, predict(mod.gbm, type = "response", n.trees = perf) > 0.5)

pred.numbers <- predict(mod.gbm, type = "response", n.trees = perf)

# gbm no devuelve el LABEL de las predicciones para multinomial,
# por tanto escogemos la de mayor probabilidad
pred_class <- apply(pred.numbers,1, which.max)

# lo pasamos a dataframe
pred_class_etiquetas <- data.frame(id = 1:length(pred_class),pred_class)

# hacer la sustitucion de numericos por label teniendo en cuenta que van alfabeticamente
pred_class_etiquetas$pred_class[pred_class_etiquetas$pred_class == "1"] <- "APROBACION"
pred_class_etiquetas$pred_class[pred_class_etiquetas$pred_class == "2"] <- "NOTIFICACIONES"
pred_class_etiquetas$pred_class[pred_class_etiquetas$pred_class == "3"] <- "ORDENAMIENTO"
pred_class_etiquetas$pred_class[pred_class_etiquetas$pred_class == "4"] <- "OTROS"

pred.gbm <- pred_class_etiquetas$pred_class

# GENERAMOS UN DATAFRAME NUEVO AÑADIENDO PREDICCIONES

predicciones <- res

predicciones <- cbind(predicciones, pred.ctree)
predicciones <- cbind(predicciones, pred.evo)
predicciones <- cbind(predicciones, pred.knn)
predicciones <- cbind(predicciones, pred.jackknife)
predicciones <- cbind(predicciones, pred.rf)
predicciones <- cbind(predicciones, pred.nb)
predicciones <- cbind(predicciones, pred.svm)
predicciones <- cbind(predicciones, pred.gbm)

# NOS QUEDAMOS SOLO CON LAS PREDICCIONES

predicciones <- predicciones[,c("LABEL","pred.ctree","pred.evo","pred.knn","pred.jackknife",
                              "pred.rf","pred.nb","pred.svm","pred.gbm")]
```

DE ESTE MODO ES MUCHO MÁS SENCILLO GENERAR MATRICES DE CONFUSIÓN

```
library(caret)
```

```
confusion.ctree <- confusionMatrix(predicciones$pred.ctree, predicciones$LABEL)
```

```
confusion.evo <- confusionMatrix(predicciones$pred.evo, predicciones$LABEL)
confusion.knn <- confusionMatrix(predicciones$pred.knn, predicciones$LABEL)
confusion.jack <- confusionMatrix(predicciones$pred.jackknife, predicciones$LABEL)
confusion.rf <- confusionMatrix(predicciones$pred.rf, predicciones$LABEL)
confusion.nb <- confusionMatrix(predicciones$pred.nb, predicciones$LABEL)
confusion.svm <- confusionMatrix(predicciones$pred.svm, predicciones$LABEL)
confusion.gbm <- confusionMatrix(predicciones$pred.gbm, predicciones$LABEL)
```

Y OBTENEMOS EL MEJOR MODELO MIRANDO EL ACCURACY

```
confusion.ctree$overall[["Accuracy"]]
  Accuracy
0.7185345
confusion.evo$overall[["Accuracy"]]
  Accuracy
8.019397e-01
confusion.knn$overall[["Accuracy"]]
  Accuracy
0.9890086
confusion.jack$overall[["Accuracy"]]
  Accuracy
0.816163793
confusion.rf$overall[["Accuracy"]]
  Accuracy
0.8849138
confusion.nb$overall[["Accuracy"]]
  Accuracy
6.478448e-01
confusion.svm$overall[["Accuracy"]]
  Accuracy
0.9002155
confusion.gbm$overall[["Accuracy"]]
  Accuracy
0.9556034
```

Queda claro que el orden de “accuracy” de los modelos, de mejor a peor es:

1. knn (0.989)
2. gbm (0.955)
3. svm (0.900)
4. RandomForest (0.884)
5. Jackknife (0.816)
6. Evolutionary Tree (0.801)
7. Conditional Inference Tree (0.718)
8. Naive-Bayes (0.647)

CONCLUSIONES

Se ha logrado en gran medida el objetivo.

Los procesos de lectura y clasificación se han acelerado mucho, principalmente en la primera fase de extracción de contenidos.

Tal y cómo hemos mencionado con anterioridad, se logran procesar más de 3.000 documentos a la semana cuando antes era habitual unos 150 en el mismo periodo de tiempo.

El número total de documentos procesados superó este mes los 26.000 dado que se ha solicitado incluso que se aplique esta metodología a antiguos proyectos

Los procesos de clasificación, por las noticias que tenemos, se han acelerado igualmente, aunque queda por evaluar la precisión del sistema predictivo, sustituir el árbol de decisión inicial por el modelo basado en knn y articular mecanismos de verificación en caso de ser necesario a partir de las indicaciones de cada uno de los departamentos.

Jose Manuel Vera Oteo, en Madrid, a 9 de Junio de 2016